



北京大学

研究报告

题目：余震预测技术国际大赛算法研究与工程实现报告

课程：人工智能导论

姓名：宁业栋

学号：2501220176

组别：个人项目

项目：阿里云天池余震预测技术国际大赛

二〇二六年五月

摘要

余震预测是地震应急响应中的高价值问题。强震发生后的前数小时至数天，余震序列会快速释放关于断层尺度、应力调整和构造背景的信息；如何利用这一早期观测窗口预测未来最大余震的震级与发生时间，是地震学经验规律、机器学习建模和工程化推理共同作用的复杂任务。本文围绕阿里云天池“余震预测技术国际大赛”构建了一套可复现的端到端算法工程，面向全球浅源强震样本，预测震后未来窗口内最大余震震级与时间差。

本研究使用 USGS 全球地震目录构建主震-余震样本，结合 Peter Bird 2002 全球板块边界数据与 Global CMT 震源机制解，形成包含 4704 条主震样本、82 列高级特征的建模数据集。特征工程部分融合 Gutenberg-Richter 定律、大森-宇津余震衰减、Båth's Law、地震生产率指数、空间各向异性、板块边界距离、震源机制类型和早期能量释放过程。模型部分以 LightGBM 与 XGBoost 为稳定主线，引入时间序列交叉验证、时间目标 $\log(1 + t)$ 变换、预测偏晚非对称惩罚和 OOF 融合；同时实现 Transformer 与有向时空因果 ST-GNN 作为可选深度模型扩展。

实验结果显示，在 5 折 TimeSeriesSplit 验证中，XGBoost 的平均时间 RMSE 为 2.454，LightGBM 非对称时间目标的平均震级 RMSE 为 1.381，树模型 OOF 融合后的震级 RMSE 为 1.370。最终一键流程生成 20 条比赛验证序列的提交文件，包含 `mainshock_id`、`predicted_max_mag` 与 `predicted_time_to_max` 三列，无缺失值且预测时间均非负。本文最后总结了当前方案的工程优势与局限，并讨论低震级完整目录、区域构造分层建模和深度时空模型进一步提升的方向。

关键词：余震预测；Gutenberg-Richter 定律；Omori-Utsu 定律；Global CMT；LightGBM；XGBoost；Transformer；ST-GNN；时间序列交叉验证

目录

摘要	I
第一章 引言	1
1.1 研究背景	1
1.2 研究目标	1
1.3 工程流水线概览	2
第二章 数据集与样本构建	3
2.1 数据源	3
2.2 主震-余震样本定义	4
2.3 目标变量分布	5
2.4 早期余震观测量	5
第三章 高级地震学特征工程	7
3.1 特征体系总览	7
3.2 Gutenberg-Richter 定律与完整性震级	7
3.3 大森-宇津定律与余震衰减	8
3.4 Bath's Law 与早期最大余震缺口	8
3.5 空间各向异性与断层方向性	9
3.6 构造背景与震源机制	9
3.7 特征有效性分析	9
第四章 模型方法	11
4.1 机器学习基线	11
4.2 Transformer 双输入融合模型	11
4.3 ST-GNN 有向时空因果图	12

目录	III
第五章 评估体系与防泄漏设计	13
5.1 时间序列交叉验证	13
5.2 评估指标	13
5.3 深度学习预处理防泄漏	14
第六章 实验结果与分析	15
6.1 交叉验证结果	15
6.2 OOF 融合	15
6.3 测试序列提交结果	16
6.4 结果讨论	18
第七章 工程化复现与部署	19
7.1 项目模块	19
7.2 一键运行	19
7.3 可复现性控制	20
第八章 结论与展望	21
参考文献	22
附录 A 附录：关键命令与产物	23
A.1 报告资产生成	23
A.2 LaTeX 编译	23
A.3 核心产物	23

第一章 引言

1.1 研究背景

大震之后的余震活动不仅影响救援安全、基础设施恢复和公众避险决策，也为理解主震破裂尺度和区域应力调整提供了重要线索。经验地震学表明，余震频率通常随时间按幂律衰减，震级频度服从 Gutenberg–Richter 关系，最大余震与主震震级差值又呈现 Bath’s Law 所描述的统计规律。然而，这些规律在不同构造环境、震源机制与观测完整性条件下会发生显著变化，单一经验公式很难覆盖全球浅源强震的复杂情形。

本项目的比赛任务要求：针对全球范围内发生的浅源强震，在主震发生后早期观测窗口内获取地震序列、构造背景和震源机制信息，预测未来特定时间段内最大余震的震级和发生时间。该任务存在三个核心难点。第一，目标分布高度零膨胀与长尾并存，大量样本未来窗口无显著余震，而少数强余震样本决定了风险上限。第二，不同构造区的余震生产率差异显著，俯冲带、走滑断层和板内地震的统计行为并不一致。第三，真实线上评测天然按时间推进，若使用随机划分会产生未来信息泄漏，导致离线指标虚高。

1.2 研究目标

本文目标不是仅给出单个模型，而是建立一套“数据–特征–模型–评估–提交”闭环工程。具体包括：


1. 构建全球浅源强震主震–余震样本，并生成与比赛提交逻辑一致的训练标签；
2. 融合地震学先验与机器学习特征，包括 G-R b 值、大森–宇津参数、Bath 缺口、空间各向异性、板块边界和 Global CMT 震源机制；
3. 建立严格时间序列验证体系，避免未来数据穿越；
4. 训练 LightGBM、XGBoost 基线模型，并以 OOF 方式搜索融合权重；

5. 实现 Transformer 和 ST-GNN 深度模型接口，为后续深度时空建模预留可复现路径；
6. 输出可一键运行的比赛推理流水线和标准提交文件。

1.3 工程流水线概览

项目总体流程如图1.1所示。原始数据层包括 USGS 地震目录、PB2002 板块边界和 Global CMT 震源机制目录；特征层将早期余震序列转化为统计、物理和构造特征；模型层以树模型为主线，并保留深度序列模型；推理层对每个测试序列实时提取特征并输出提交格式。

余震预测工程流水线



全流程固定随机种子，并采用时间序列切分防止未来信息泄漏

图 1.1: 余震预测工程流水线

第二章 数据集与样本构建

2.1 数据源

本项目使用多源地震学数据。USGS 地震目录提供事件时间、经纬度、深度和震级，是主震识别与早期余震序列重建的基础；PB2002 板块边界提供最近边界距离和边界类型；Global CMT 提供震源机制解，刻画断层滑动方式。主要数据源见表2.1。

表 2.1: 数据源与用途

数据源	路径	用途
USGS Mw $\geq$ 4.0 浅源目录	USGS_Mw4.0_Depth70_1970-2023.csv	重建主震后 3 天早期余震序列
USGS Mw $\geq$ 6.0 主震目录	USGS_Mw6.0_Depth70_1970-2023.csv	确定强震主震样本
PB2002 板块边界	PB2002_boundaries.json	最近板块边界距离与边界类型
Global CMT	GlobalCMT_1976-2024.csv	震源机制 strike/dip/rake 与断层类型
比赛验证序列	data/test_sequences/*_eq.csv	20 条单序列推理验证

处理后的样本规模见表2.2。当前高级特征表包含 4704 条主震样本、82 列字段，其中训练脚本自动筛选 74 个数值特征进入树模型。20 条比赛验证序列已经通过推理脚本生成提交文件。

表 2.2: 样本与特征规模

统计项	数值
主震样本数	4711
高级特征列数	83
模型输入特征数	94
目标最大余震非零样本	2981
目标时间非零样本	2981
提交序列数	20

2.2 主震—余震样本定义

设主震发生时刻为 t_0 ，震中位置为 (ϕ_0, λ_0) 。本研究以主震后 $T_{\text{obs}} = 3$ 天作为早期观测窗口，以震中半径 $R = 100$ km 作为空间窗口，筛选满足

$$0 < t_i - t_0 \leq T_{\text{obs}}, \quad d_i \leq R$$

的事件作为早期余震序列。未来预测目标包括两项：最大余震震级 $\hat{M}_{\text{max}}$ 与最大余震发生时间差 $\hat{t}_{\text{max}}$ 。当未来窗口内无满足条件的余震时，目标被记录为 0，这也是目标分布零膨胀的主要来源。

图2.1展示了主震样本在时间和震级维度上的分布。样本时间跨度为 1970 年至 2023 年，覆盖全球仪器记录较完整的现代时期。震级分布集中在 $M_w 6.0$ 附近，较大震级样本数量迅速下降，这符合强震频度随震级增加而指数衰减的基本规律。




图 2.1: 主震样本分布

2.3 目标变量分布

最大余震震级与发生时间分布如图2.2所示。未来窗口内没有显著余震的样本占比较高，使得 `target_max_mag` 和 `target_time_to_max_days` 在 0 附近聚集。与此同时，发生时间目标具有明显长尾，最大值接近 27 天。若直接回归原始时间，模型容易被少数大时间样本主导；因此训练时对时间目标使用

$$y'_t = \log(1 + y_t)$$

进行压缩，预测输出再通过 $\exp(y'_t) - 1$ 还原到真实天数。




图 2.2: 预测目标分布

2.4 早期余震观测量

早期余震数量是最直接的序列强度指标。图2.3显示，多数主震在 3 天、100 km 窗口内只有少量事件，而少数大震或高余震生产率区域会产生密集余震序列。这种长尾特征使得线性模型难以充分表达，因此树模型和序列模型都更适合捕捉非线性关系。




图 2.3: 早期余震数量分布

第三章 高级地震学特征工程

3.1 特征体系总览

本项目没有只依赖简单统计量，而是将传统地震学规律转化为可学习特征。表3.1给出了主要特征组及物理含义。

表 3.1: 核心特征组说明

特征组	代表字段	物理含义
地震活动性	early/count/energy	早期余震数量、能量、分箱释放过程
G-R 定律	gr_b_value/gr_a_value/gr_mc	MAXC 估计 M_c , Aki-Utsu MLE 估计 b 值
大森-宇津	omori_p/omori_c/omori_k	非齐次泊松过程 MLE 拟合余震衰减
Båth/生产率	bath_deficit/productivity_index	刻画主震后最大余震缺口与生产率水平
空间各向异性	anisotropy_*	用协方差主轴表征破裂方向性
地质构造	plate_type_*/distance	最近板块边界类型和距离
震源机制	strike/dip/rake/fault_type_*	Global CMT 断层滑动类型与 P/T 轴

3.2 Gutenberg–Richter 定律与完整性震级

Gutenberg–Richter 定律描述某区域内震级不小于 M 的地震累计频度：

$$\log_{10} N(M) = a - bM.$$

其中 b 值反映大小地震的相对比例，常被解释为应力状态、介质非均匀性和破裂尺度的统计指示。为了避免将观测不完整的小震纳入估计，本项目采用最大曲率法 (Maximum Curvature, MAXC) 估计完整性震级 M_c ：对早期余震震级按固定 bin 统计，频次最高的 bin 作为 M_c 。随后使用 Aki–Utsu 极大似然估计：

$$b = \frac{\log_{10} e}{\bar{M} - (M_c - \Delta M/2)}.$$

在得到 a 与 b 后，进一步构造地震生产率指数

$$I_p = a - bM_{\text{main}},$$

用于刻画在给定主震震级条件下的相对余震生产能力。

3.3 大森—宇津定律与余震衰减

大森—宇津定律描述余震发生率随时间衰减：

$$\lambda(t) = \frac{K}{(t + c)^p}.$$


其中 p 控制衰减速度， c 描述主震后极早期观测不完整或短时饱和效应， K 近似表征余震生产率。本项目将余震序列视为非齐次泊松过程，最小化负对数似然估计 p, c, K 。若 p 的优化结果贴近边界，则标记为无效，避免将优化器“撞边界”的结果作为稳定物理参数。

3.4 Båth's Law 与早期最大余震缺口


Båth's Law 经验上认为最大余震通常比主震低约 1.2 级。比赛任务直接预测未来最大余震，因此早期窗口内已经出现的最大余震强度具有重要意义。本项目定义：

$$D_{\text{Bath}} = M_{\text{main}} - M_{\text{early,max}}.$$

若 D_{Bath} 较小，说明早期已经出现接近主震规模的较强余震；若缺口较大，则未来仍可能存在显著释放空间。图3.1展示了 Båth 缺口和生产率指数与目标最大余震之间的关系。散点较为离散，说明单一物理特征不足以直接决定结果，但其为树模型提供了有效的非线性分裂依据。



(a) Båth 缺口与最大余震



(b) 生产率指数与最大余震

图 3.1: 地震学先验特征与目标变量关系

3.5 空间各向异性与断层方向性

余震往往沿主震破裂面或触发断层带展布。为表征这一方向性，本文将早期余震相对主震位置投影到局部平面：

$$x = R_{\oplus} \cos \phi_0 (\lambda - \lambda_0), \quad y = R_{\oplus} (\phi - \phi_0).$$

随后对 (x, y) 坐标计算协方差矩阵并做特征分解，得到主轴长度、短轴长度、长短轴比和方位角。若早期余震数少于 3 条，则各向异性特征标记为无效。

3.6 构造背景与震源机制

板块边界距离与边界类型反映主震所处构造背景。PB2002 边界数据被读取为 GeoDataFrame 后，通过最近邻空间连接获得主震到最近板块边界的近似距离和类别。当前样本中最近边界类型以 SUB 和 UNK 为主，分布如图3.2所示。

Global CMT 震源机制进一步提供断层滑动方向。本文采用严格匹配条件：主震时间差小于 60 秒，空间距离小于 50 km。有效匹配样本为 4022 条，最大时间差 11.84 秒，最大距离 46.75 km。根据 $rake_1$ 将断层类型划分为 Thrust、Normal、Strike-Slip 与 Unknown。图3.2同时展示了震源机制类型分布，走滑型和逆冲型样本占比较高。




图 3.2: 构造背景与震源机制特征

3.7 特征有效性分析

由于部分物理模型要求最小事件数，所有高级特征并非对每个样本都有效。表3.2和图3.3给出了特征有效率。GCMT 震源机制有效率最高，达到 85.50%；Bath 特征有效率为 63.80%；G-R b 值有效率约为 25.87%；Omori 和 ETAS 对事件数要求更高，有效率较低。这一结果提示后续若要提高物理参数覆盖率，需要更完整的低震级局部目录。

表 3.2: 高级特征有效率统计

特征模块	有效样本数	有效率
G-R b 值	1218	25.85%
Omori 参数	503	10.68%
空间各向异性	1854	39.35%
ETAS 参数	800	16.98%
Båth 特征	3004	63.77%
GCMT 震源机制	4028	85.50%




图 3.3: 高级特征有效率柱状图

第四章 模型方法

4.1 机器学习基线

树模型是当前工程的稳定主线。LightGBM 与 XGBoost 都能处理非线性特征交互，并对缺失值具有较好鲁棒性，适合当前“物理特征部分缺失、类别 one-hot 与连续变量混合”的特征结构。项目中训练两个目标：最大余震震级与最大余震时间。震级目标保持原尺度，时间目标使用 $\log(1 + t)$ 长尾压缩。

LightGBM 的时间目标额外支持非对称自定义损失。设真实时间为 t ，预测时间为 $\hat{t}$ ，若 $\hat{t} > t$ ，表示预测晚于实际发生时间，预警场景下风险更高。因此定义：

$$\mathcal{L}_t = \begin{cases} \alpha(\hat{t} - t)^2, & \hat{t} > t, \\ (\hat{t} - t)^2, & \hat{t} \leq t, \end{cases} \quad \alpha = 2.$$

该损失在真实天数尺度判断“偏晚”，并通过链式法则返回 $\log$ 预测尺度上的梯度和 Hessian，使训练目标与业务风险更一致。

4.2 Transformer 双输入融合模型

深度学习模型采用“事件序列 + 全局特征”的双输入结构。早期余震序列被编码为

$$x_i = [\Delta t_i, \log(1 + \Delta t_i), \Delta x_i, \Delta y_i, d_i, \text{depth}_i, M_i],$$

经线性投影和正弦位置编码送入 Transformer Encoder。全局手工特征经 MLP 编码后与序列池化向量拼接，最终输出震级和 $\log$ 时间。为避免数据泄漏，序列特征与全局特征的 RobustScaler 只在时间切分后的训练集上拟合，验证和推理阶段只复用已保存预处理器。

4.3 ST-GNN 有向时空因果图


仅用 Transformer 处理序列会弱化余震空间传播结构。ST-GNN 将每个早期余震事件视为图节点，并构建有向时空边。给定事件 i, j ，仅当

$$d_{ij} < R_g, \quad t_i < t_j$$

时，才允许边 $i \rightarrow j$ 存在。消息传递采用 $A[\text{target}, \text{source}]$ 约定，即未来节点只能聚合过去节点的信息，避免信息从未来倒流。边权使用高斯核：

$$A_{ji} = \exp\left(-\frac{d_{ij}^2}{2\sigma^2}\right).$$

图4.1展示了该有向因果构图方式。该模型目前作为可选增强路径，默认一键流程仍采用树模型提交，以保证速度和稳定性。



构图约束：距离 $< R$ 且 $\text{time}[\text{source}] < \text{time}[\text{target}]$ ，信息仅从过去流向未来

图 4.1: ST-GNN 有向时空因果图示意

第五章 评估体系与防泄漏设计

5.1 时间序列交叉验证

地震目录具有强时间顺序属性。若随机 K 折划分，模型可能在训练阶段看到未来年份的构造分布和地震序列特征，从而造成数据穿越。本项目使用 TimeSeriesSplit：每一折都使用更早时间段训练，验证集严格位于训练集之后。表5.2列出了每折训练后的验证时间段与指标。

Fold	模型	验证起点	验证终点	Mag RMSE	Time RMSE	Asym MAE
1	baseline	1984-07-02	1993-12-09	0.543	8.448	9.403
1	xgboost	1984-07-02	1993-12-09	0.539	8.704	8.579
2	baseline	1993-12-10	2002-01-28	0.580	8.446	9.147
2	xgboost	1993-12-10	2002-01-28	0.571	8.654	8.400
3	baseline	2002-02-03	2008-11-22	0.540	8.601	9.485
3	xgboost	2002-02-03	2008-11-22	0.533	8.621	8.775
4	baseline	2008-11-22	2016-02-17	0.511	8.082	9.037
4	xgboost	2008-11-22	2016-02-17	0.505	8.465	8.448
5	baseline	2016-03-02	2023-12-21	0.480	8.193	9.104
5	xgboost	2016-03-02	2023-12-21	0.473	8.414	8.371

表 5.2: 时间序列交叉验证每折指标

5.2 评估指标

常规指标包括震级 RMSE/MAE 与时间 RMSE/MAE：

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|.$$

考虑预警场景下“预测偏晚”的风险更大，本文还计算非对称时间误差：

$$\text{AsymMAE} = \frac{1}{n} \sum_i w_i |\hat{t}_i - t_i|, \quad w_i = \begin{cases} 2, & \hat{t}_i > t_i, \\ 1, & \hat{t}_i \leq t_i. \end{cases}$$

该指标将模型从纯数值拟合引向预警风险控制。

5.3 深度学习预处理防泄漏

深度模型对尺度敏感，但 scaler 的拟合如果在全量数据上完成，会将未来验证集分布泄漏给训练过程。因此项目采用如下策略：

1. 先按 `mainshock_time` 排序并切分训练集、验证集；
2. 仅用训练集调用 `fit_dataset_preprocessors`；
3. Dataset 构造阶段只接收并 transform，不在内部 fit；
4. 预处理器随模型一同保存，推理时复用同一对象。

这一设计保证深度模型与树模型遵循同样的时间因果原则。


第六章 实验结果与分析

6.1 交叉验证结果


平均验证指标见表6.1。LightGBM 与 XGBoost 的震级 RMSE 非常接近, XGBoost 在时间 MAE 与非对称 MAE 上更优, 因此最终 OOF 融合给予 XGBoost 更高权重。图6.1进一步展示了各折 RMSE 与时间非对称指标变化。第三折时间 RMSE 较高, 说明 1998–2006 年段可能包含更复杂或更极端的余震序列, 对模型泛化提出挑战。

表 6.1: 模型平均验证指标

模型	Mag RMSE	Mag MAE	Time RMSE	Time MAE	Asym MAE	Asym RMSE
baseline	0.531	0.425	8.354	6.729	9.235	9.374
xgboost	0.524	0.421	8.572	6.716	8.515	9.167



(a) 各折 RMSE



(b) 时间非对称指标

图 6.1: 模型验证指标对比

6.2 OOF 融合

模型融合基于 OOF 预测搜索线性权重。当前最优权重为 LightGBM 0.32、XGBoost 0.68, DL 和 GNN 默认权重为 0, 表示稳定提交路径仅使用树模型。融合摘要

见表6.2，权重可视化见图6.2。融合后 OOF 震级 RMSE 为 1.370，综合目标为 3.903。

表 6.2: 融合权重与 OOF 指标

项目	数值
baseline	0.12
xgboost	0.88
dl	0.00
gnn	0.00
OOF Mag RMSE	0.525
OOF Time RMSE	8.445
OOF Ensemble Objective	9.658




图 6.2: OOF 融合权重

6.3 测试序列提交结果

20 条比赛验证序列的预测结果见表6.4。最终提交文件包含 mainshock_id、predicted_max_mag、predicted_time_to_max 三列，预测时间均非负。图6.3展示了预测震级和时间的分布，其中 2011 年日本东北地震序列的预测时间显著偏长，符合其大型俯冲带地震后余震持续活跃的直觉。

主震 ID	预测最大余震 Mw	预测时间差（天）
20010126031640_eq	4.700	0.390
20021103221241_eq	4.900	0.165

主震 ID	预测最大余震 Mw	预测时间差 (天)
20031227160059_eq	6.770	5.145
20041226005853_eq	6.100	0.249
20070815234057_eq	5.000	1.310
20080512062804_eq	5.000	0.953
20100227080123_eq	4.400	0.356
20110311054624_eq	6.466	18.346
20120411083836_eq	5.600	0.608
20130420000246_eq	4.000	0.728
20150425061125_eq	4.800	0.565
20190706031953_eq	4.100	0.276
20201030115127_eq	4.000	0.081
20210521134834_eq	3.400	1.109
20210521180411_eq	4.400	0.769
20210814122908_eq	4.200	0.341
20220905045218_eq	3.800	0.212
20230206011734_eq	4.800	0.776
20231202143704_eq	4.600	1.825
20240122180905_eq	4.100	0.386

表 6.4: 20 条测试序列预测结果




图 6.3: 20 条测试序列预测分布

6.4 结果讨论

从结果看，当前树模型已经形成稳健基线，但仍存在若干可解释现象。首先，目标变量零值比例高，导致总体 MAE 看似较低，但强余震样本的 RMSE 仍然决定模型上限。其次，G-R、Omori 和 ETAS 特征有效率受早期余震数量限制，在事件稀疏样本上依赖缺失值处理和 missing indicator。第三，GCMT 严格匹配带来高质量震源机制特征，但仍有 682 条样本未匹配，Unknown 类别本身也是模型需要学习的状态。最后，XGBoost 在时间指标上更稳定，可能与其正则化和树结构搜索方式有关，而 LightGBM 的非对称目标在震级维度保持较好表现。

第七章 工程化复现与部署

7.1 项目模块

项目结构已经按数据、特征、模型、训练、评估和推理分层，核心模块见表7.1。

表 7.1: 工程模块职责

模块	职责
main.py	统一命令入口，串联下载、序列、特征、训练和推理
run.sh	一键比赛流水线，支持跳过下载和可选 DL/GNN
src/data_loader.py	主震-余震序列构建与目标生成
src/features.py	地震学特征、板块边界、GCMT 震源机制融合
src/models.py	LightGBM/XGBoost Baseline 与非对称目标
src/dataset.py	深度学习序列 Dataset、防泄漏预处理器
src/models_dl.py	Transformer 双输入融合模型
src/models_gnn.py	有向时空因果 ST-GNN
scripts/make_submission.py	端到端单序列推理与提交格式化

7.2 一键运行

完整流程可通过 `run.sh` 执行。默认模式跳过深度模型，仅训练 LightGBM 与 XGBoost，适合快速稳定提交；若需要探索深度模型，可额外加入 `--with-dl` 或 `--with-gnn`。

Listing 7.1: 一键运行命令

```
./run.sh --skip-download
./run.sh --skip-download train-only
./run.sh --skip-download --with-dl train-only
./run.sh --skip-download --with-gnn train-only
```

推理脚本对单条测试序列执行实时特征提取、模型加载、融合预测和后处理裁剪。若深度模型权重大于 0 但产物缺失，脚本会跳过该模型并对剩余可用模型重新归一化权重；若所有模型均不可用，除非显式允许规则兜底，否则抛出错误，避免静默生成不可信结果。

7.3 可复现性控制

项目从以下层面控制可复现性：

1. 固定随机种子，训练脚本记录 seed、模型参数和时间目标变换；
2. 使用时间序列切分，不采用随机 K 折；
3. 模型产物与特征列同步保存，推理按训练列补齐缺失特征；
4. 深度学习预处理器保存为 joblib，推理复用训练时 scaler 和填充值；
5. 输出 `model_meta.json`、`feature_cols.json`、`ensemble_weights.json` 作为模型语义说明。

第八章 结论与展望

本文构建了一套面向余震预测比赛的完整算法工程。特征工程方面，项目将 G-R、Omori、Båth's Law、生产率指数、空间各向异性、板块构造和 Global CMT 震源机制融合为 82 列高级特征；模型方面，使用 LightGBM 与 XGBoost 建立稳定树模型基线，并通过时间目标 log 变换、非对称时间惩罚和 OOF 融合增强预警语义；工程方面，实现了从数据构建到提交文件生成的一键流水线。

当前方案的主要优势在于稳健、可解释和可复现。地震学特征为模型提供物理先验，时间序列交叉验证避免未来信息泄漏，提交流水线能够处理单条新主震序列。局限也较明确：物理参数有效率仍受早期事件数限制，目标零膨胀尚未单独建模，深度模型目前以可选增强为主，尚未通过系统超参搜索充分发挥能力。

后续可从三方面继续提升。第一，引入更完整的区域低震级目录，提高 G-R、Omori 和 ETAS 参数覆盖率。第二，按俯冲带、走滑边界、板内地震和震源机制类型进行分层建模，减少全球模型的异质性压力。第三，对 Transformer 与 ST-GNN 进行 OOF 训练和权重搜索，使深度模型真正参与融合，而非仅作为接口储备。

参考文献

- [1] Gutenberg, B., and Richter, C. F. Frequency of earthquakes in California. *Bulletin of the Seismological Society of America*, 1944.
- [2] Aki, K. Maximum likelihood estimate of b in the formula $\log N = a - bM$ and its confidence limits. *Bulletin of the Earthquake Research Institute*, 1965.
- [3] Utsu, T. A statistical study on the occurrence of aftershocks. *Geophysical Magazine*, 1961.
- [4] Utsu, T., Ogata, Y., and Matsu'ura, R. S. The centenary of the Omori formula for a decay law of aftershock activity. *Journal of Physics of the Earth*, 1995.
- [5] Båth, M. Lateral inhomogeneities of the upper mantle. *Tectonophysics*, 1965.
- [6] Bird, P. An updated digital model of plate boundaries. *Geochemistry, Geophysics, Geosystems*, 2003.
- [7] Dziewonski, A. M., Chou, T. A., and Woodhouse, J. H. Determination of earthquake source parameters from waveform data for studies of global and regional seismicity. *Journal of Geophysical Research*, 1981.
- [8] Ke, G., Meng, Q., Finley, T., et al. LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 2017.
- [9] Chen, T., and Guestrin, C. XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 2016.
- [10] Vaswani, A., Shazeer, N., Parmar, N., et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.

附录 A 附录：关键命令与产物

A.1 报告资产生成

Listing A.1: 生成报告图表与表格

```
python scripts/build_report_assets.py
```

A.2 LaTeX 编译

Listing A.2: 编译研究报告

```
cd reports/aftershock_research_report  
latexmk -xelatex -interaction=nonstopmode aftershock_research_report.tex
```

A.3 核心产物

- 高级特征表: data/processed/advanced_features.csv
- 交叉验证指标: data/models/cv_metrics.csv
- 模型元信息: data/models/model_meta.json
- 融合权重: data/models/ensemble_weights.json
- 提交文件: data/processed/submission.csv